

[IC] Estimativa do espectro de transmissão de LPFGs utilizando arranjo FBG modulado por estresse e Rede Neural

Felipe Barino*, Daniel Discini†, Thiago Coelho‡ e A. Bessa dos Santos§

Departamento de Circuitos, Universidade Federal de Juiz de Fora

*felipe.barino@engenharia.ufjf.br, †danielsilveira@engenharia.ufjf.br,

‡thiago.coelho@ufjf.edu.br, §alexandre.bessa@engenharia.ufjf.br

Resumo—Este trabalho propõe uma nova abordagem para interrogação de sensores ópticos, envolvendo técnicas de interrogação baseadas tanto em análise de potência quanto em análise do espectro de transmissão. O objetivo principal do trabalho é desenvolver uma alternativa simples e barata ao Analisador de Espectro usando 5 FBGs modulados por estresse e uma rede neural para realizar a regressão do espectro. Acurácia na mesma ordem da resolução do espectro foi obtida com o método proposto.

Palavras-chave—sensor óptico, interrogação, redes de período longo, redes de Bragg, redes neurais

I. INTRODUÇÃO

Os avanços do mercado na área de instrumentação vêm beneficiando o desenvolvimento da tecnologia de sensores ópticos devido ao aumento da oferta de componentes ópticos a um bom custo-benefício e com diversas opções de fornecedores [1]. As chamadas Redes de Bragg (Fiber Bragg Grating - FBG) e Redes de Período Longo em Fibra (Long Period Fiber Grating - LPFG) são duas estruturas importantes no sensoramento por fibra óptica. Ambas são redes de difração escritas dentro da própria fibra por meio da modulação periódica do índice de refração.

As Redes de Período Longo em Fibra (LPFGs) são estruturas mais simples de serem fabricadas, quando comparadas às Redes de Bragg, uma vez que seu período de modulação é consideravelmente maior. Seu uso como sensor ocorre, pois o comprimento de onda central da banda de rejeição do m -ésimo modo de propagação, denotado por λ_{res}^m , é função de parâmetros que podem variar com o ambiente, como o índice de refração do núcleo $n_{eff,co}$, da casca $n_{eff,cl}$ e também do período Λ da LPFG, [2], [3]. Essa relação é dada por:

$$\lambda_{res}^m = (n_{eff,co} - n_{eff,cl}^m)\Lambda \quad (1)$$

Dessa maneira deve-se correlacionar a grandeza medida pelo sensor com a variação do espectro de transmissão do dispositivo. A esse processo dá-se o nome de interrogação e para tal alguns métodos são utilizados e, em sua maioria, requerem equipamentos grandes e de grande custo. Uma abordagem consiste em aplicar uma fonte luminosa de espectro largo ao sensor óptico e observar o espectro em um Analisador de Espectro Óptico (OSA), outra técnica utiliza lasers com comprimento de onda central variável [4], [5]. Uma solução

mais barata e compacta consiste em adicionar filtros em cascata com o sensor que se deseja interrogar e analisar, através de fotodetectores, a potência nesses [6]–[8].

Aqui se apresenta uma técnica mista, de modo que, com base na potência em um arranjo de filtros em cascata com a LPFG estima-se seu espectro de transmissão. Para isso são utilizados 5 filtros FBGs, modulados pela aplicação de uma força transversal, 5 fotodetectores os quais têm suas leituras enviadas a uma rede neural treinada que retorna o espectro de transmissão da LPFG.

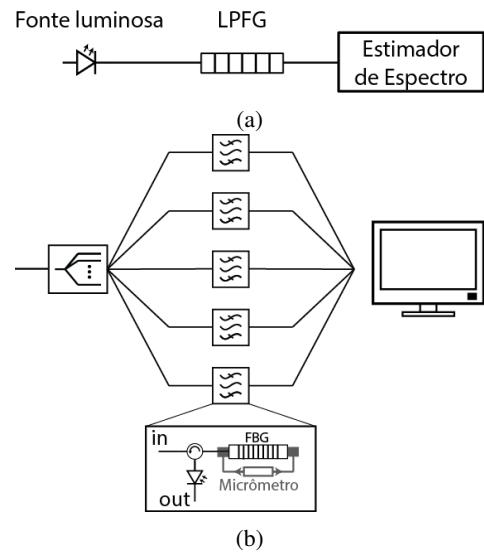


Figura 1: (a) *Setup* experimental. (b) Esquema do estimador de espectro proposto.

II. METODOLOGIA

A. Setup

O *setup* experimental proposto nesse trabalho consiste em uma fonte luminosa de espectro largo, uma LPFG que se deseja interrogar e o estimador de espectro estudado, como ilustrado na Figura 1a. O Estimador de Espectro, esquematizado na Figura 1b, consiste em um arranjo com cinco FBGs e um Computador Pessoal (PC). Para cada FBG desse arranjo há: um micrometro, um circulador óptico e um fotodetector.

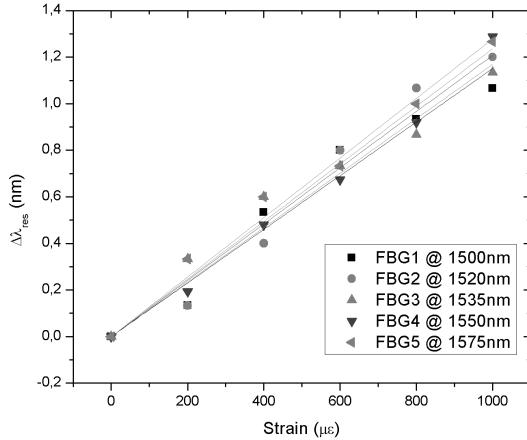


Figura 2: Ajuste linear para a variação de deformação nas cinco FBGs do arranjo.

Vale ressaltar que o PC aqui ilustrado pode ser substituído por um microcontrolador após a calibração do sistema.

B. Caracterização das FBGs

As FBGs foram simuladas no software *OptiGrating* com os seguintes comprimentos de onda ressonante: 1500 nm, 1520 nm, 1535 nm, 1550 nm e 1570 nm. A sensibilidade das FBGs foi obtida por meio da caracterização de cada uma dessas, variando a deformação longitudinal de 100 $\mu\epsilon$ a 1000 $\mu\epsilon$ e analisando o comprimento de onda ressoante. Uma reta com coeficiente linear nulo foi ajustada para cada FBG, a fim de se obter a sensibilidade desta à variação de deformação. Os resultados podem ser vistos na Figura 2.

C. Fotodetector

A simulação dos fotodetectores foi feita a partir da potência óptica do espectro de reflexão de cada FBG, calculada por meio de integração numérica trapezoidal, uma vez que a potência óptica de um espectro pode ser obtida pela integração da curva de espectro e a divisão desta pela resolução do OSA, vide (2), onde $R(\lambda)$ é o espectro de reflexão da FBG e $\Delta\lambda_{OSA}$ a resolução do OSA.

$$P_{fotodetector} \approx \frac{1}{\Delta\lambda_{OSA}} \int R(\lambda) d\lambda \quad (2)$$

O espectro de uma LPFG e do arranjo FBG utilizado para filtrar esta pode ser visto na Figura 3, nela estão destacadas as potências ópticas em cada FBG do arranjo.

D. Banco de dados

Com base em 24 medidas do espectro de quatro LPFGs diferentes, o sistema de aquisição de dados proposto foi simulado. Para cada espectro do banco de dados, as FBGs foram submetidas a estresses variando de 0 $\mu\epsilon$ a 1000 $\mu\epsilon$, com passo de 100 $\mu\epsilon$. Logo, para cada FBG do arranjo são feitas 11 medidas de potência pelo fotodetector. O total de 55 medidas

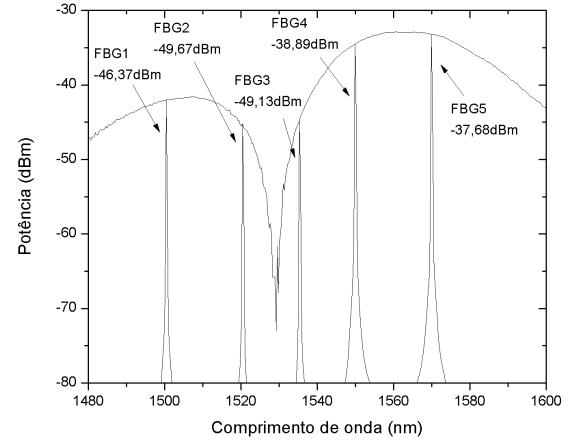


Figura 3: Espectro da LPFG e do arranjo FBG, com as respectivas leituras dos fotodetectores.

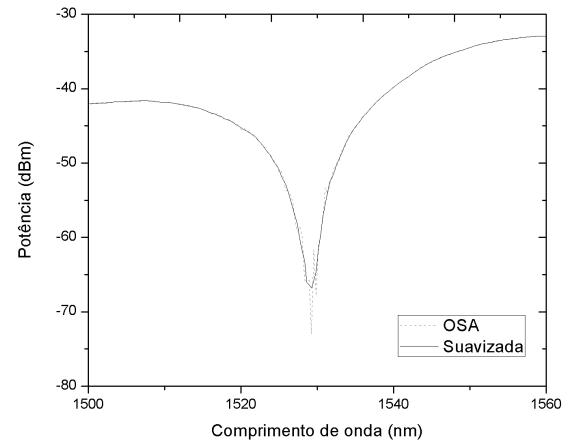


Figura 4: Espectro da LPFG obtido no OSA juntamente com o mesmo espectro suavizado pelo filtro média-móvel.

deste arranjo será utilizado como entrada da rede neural que compõe o estimador, indicando o tamanho da camada de entrada da rede neural.

Os espectros de referência foram tratados com filtro média-móvel para suavização, como pode ser visto na Figura 4, pois uma curva suave facilita a identificação do comprimento de onda ressonante. Essas amostras também tiveram o número de pontos reduzidos para diminuir a complexidade do estimador. Foram utilizados 133 pontos com os mesmos valores de comprimento de onda ressonante, podendo reduzir o espectro a um vetor. Esses resultados são utilizados como saídas desejadas para o estimador e indicam, portanto, o tamanho da camada de saída da rede neural. Por fim esses resultados foram separados entre grupos de treinamento, teste e validação com 70%, 15% e 15% do banco de dados para cada um.

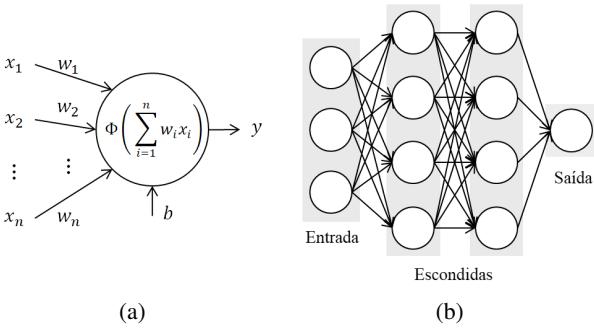


Figura 5: (a) Esquema de um neurônio artificial. (b) Esquema de uma rede neural artificial com três entradas, duas camadas escondidas (com quatro neurônios em cada e bias omitidos por simplificação) e uma saída

E. Rede Neural

O estimador de espectro em si se trata de uma Rede Neural *fitnet*, com uma camada escondida e função de ativação *sigmoid* nos neurônios desta. Uma rede neural é um modelo computacional cujo funcionamento é inspirado no sistema nervoso central de animais. Esse modelo consiste em um conjunto de unidades, chamadas de neurônios, interconectadas capaz de mapear valores de entradas em saídas com base em exemplos que o sistema aprendeu durante a fase de treinamento.

Da mesma forma que um neurônio biológico processa informação e a transmite para outros neurônios do sistema nervoso, os neurônios de uma rede neural recebem valores de entrada (da entrada do sistema em si ou de outro neurônio) que são combinados em uma soma ponderada com coeficientes determinados durante o treinamento da rede, o valor dessa combinação linear é passado então por uma função de ativação e o resultado desta para sua saída (sendo essa a saída da rede neural (ou a entrada de outro neurônio). Um neurônio artificial está esquematizado na Figura 5a.

Tais neurônios são organizados em camadas, sendo a primeira delas a camada de entrada, as seguintes são chamadas de camadas escondidas e a última de camada de saída, como ilustrado na Figura 5b.

A topologia de rede neural utilizada nesse trabalho, com função de ativação *sigmoid*, é chamada de *Multilayer Perceptron* e é capaz de mapear, quando devidamente treinada, um grupo de entradas em um grupo de saídas, sendo assim ela realiza a regressão de uma dada função [9].

O método de treinamento utilizado para realizar a regressão do espectro da LPFG com base nas leituras de potência das FBGs foi o algoritmo nativo da *Neural Network Toolbox* do MATLAB: *Bayesian regularization backpropagation*. A escolha do algoritmo foi feita, pois algoritmos com regularização tem como objetivo não apenas minimizar o erro da rede neural, mas também minimizar o valor dos pesos. Dessa forma a resposta do sistema é mais suave e, portanto, apresenta melhor generalização [10]. Como o banco de dados apresentado possui poucas observações, um algoritmo com melhor generalização é

grande valia, apesar do alto custo computacional do algoritmo utilizado.

III. RESULTADOS

A. Seleção da RNA

Após a escolha da topologia de Rede Neural, do método de treinamento desta e da identificação do tamanho da camada de entrada (55 neurônios) e de saída (133 neurônios), foram simuladas redes neurais com diferentes tamanhos. O número de neurônios da camada escondida foi variado de 4 até 32, com 10 repetições para cada caso. Os resultados foram comparados com relação ao erro médio quadrático e ao coeficiente de determinação, tanto do banco de dados de treinamento quanto de testes.

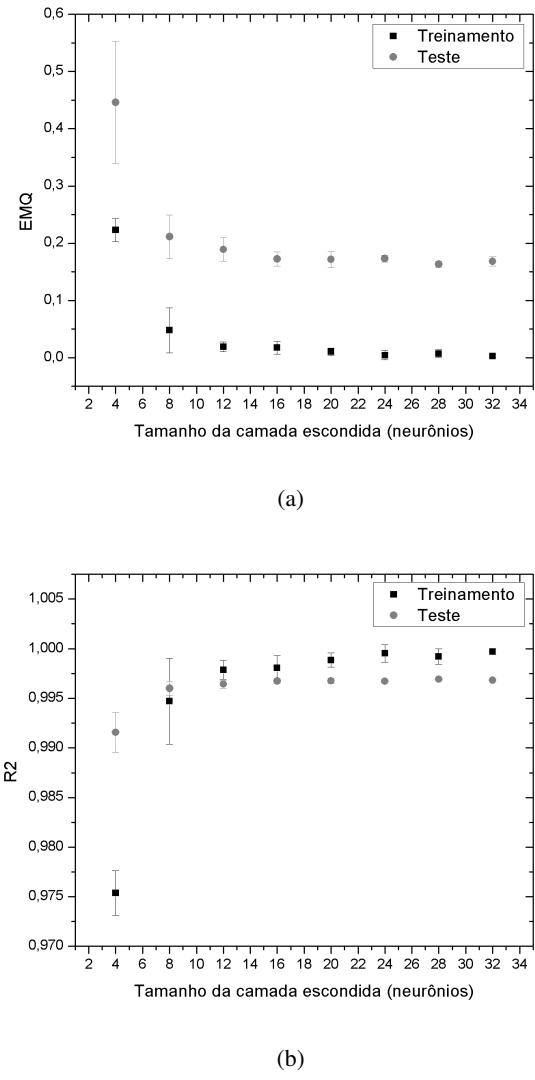


Figura 6: (a) Relação entre tamanho da camada escondida e Erro Médio Quadrático (EMQ). (b) Relação entre tamanho da camada escondida e R^2

Vale ressaltar que busca-se uma rede com o menor erro possível tanto para a fase de treinamento quanto de teste, sem

muita discrepância entre eles, fato que indica boa performance com relação aos dados não vistos durante o treinamento. Quanto ao coeficiente de determinação, uma boa rede neural deve apresentar R^2 próximo à unidade tanto para o treino quanto para o teste, indicando que o resultado se afasta do aleatório. O resultado para as 80 simulações feitas pode ser visto na Figura 6a e na Figura 6b.

Note nas Figuras 6a e 6b que para um número maior que 16 neurônios na camada escondida há pouca variação tanto no Erro Médio Quadrático (EMQ) quanto no R^2 do banco de dados de teste, indicando que não há melhora de generalização para redes neurais maiores que esta. Sendo assim, foi estabelecido o tamanho da camada escondida como 16 neurônios.

B. Estimativa do Espectro

Uma rede neural de tamanho 55x16x133, foi treinada e sua performance é discutida. Vale ressaltar que essa estimativa corresponde a um intervalo de 1500 nm a 1580 nm com os 133 pontos igualmente espaçados, portanto a resolução obtida é de 600 pm.

Na Figura 7 está ilustrada a performance da rede neural ao longo de seu treinamento, a linha acompanhada de quadrados representa o EMQ do banco de dados de treinamento, em círculos o EMQ do banco de dados de teste, por fim em triângulos o EMQ do banco de dados de validação. Este último é usado para evitar que a rede neural perca em generalização, parando o treinamento da mesma quando a performance do banco de dados de validação aumenta continuamente por seis épocas seguidas, neste caso.

Tabela I: Avaliação dos erros nos espectros estimados.

	EMQ (dB^2)	$\delta\lambda_{res}$ (nm)
Treino	0.0462	0.0380
Teste	0.3084	1.0633
Validação	0.4171	0.7595

a respeito do erro em relação à grandeza a ser media. Sendo assim, a diferença entre o vale de ressonância estimado e o real foi calculada, e denotada por $\delta\lambda_{res}$.

O erro na estimativa do comprimento de onda ressonante é uma medida de grande valor para análise da qualidade do sistema de interrogação, uma vez que é a partir de sua variação que se estima a grandeza que se deseja medir, na Tabela I estão descritos os erros do estimador de espectros proposto, tanto em relação ao erro geral da curva (pelo EMQ) quanto pelo erro médio absoluto no comprimento de onda ressonante (simbolizado por $\delta\lambda_{res}$).

Note que enquanto o erro médio no comprimento de onda ressonante do grupo de teste é menor que a resolução do espectro utilizado para treinamento da rede neural, o erro médio no grupo de teste e treino se mantém menor que duas vezes essa resolução. Sendo assim, pode-se aumentar a qualidade do sensor proposto aumentando a resolução dos espectros, que foi diminuída propositalmente na fase de pré-processamento a fim de reduzir o custo computacional do treinamento da rede neural.

Abaixo têm-se a comparação entre um espectro real e a estimativa obtida pelo interrogador aqui proposto, ou seja, a saída da rede neural. A curva em questão pertence ao banco de dados de teste, com EMQ igual a 0.1502 e $\delta\lambda_{res}$ igual a 0.6076 nm.

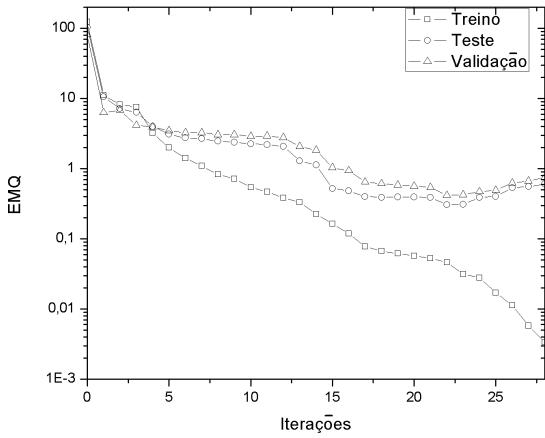


Figura 7: Performance da rede neural durante o treinamento.

A performance do método proposto pode ser avaliada com respeito à qualidade da aproximação obtida em relação ao espectro desejado, para tal o EMQ das amostras de cada subgrupo do banco de dados foi calculado. Enquanto esse parâmetro é uma medida geral do quanto a curva estimada se aproxima da curva real do espectro, ela dá pouca informação

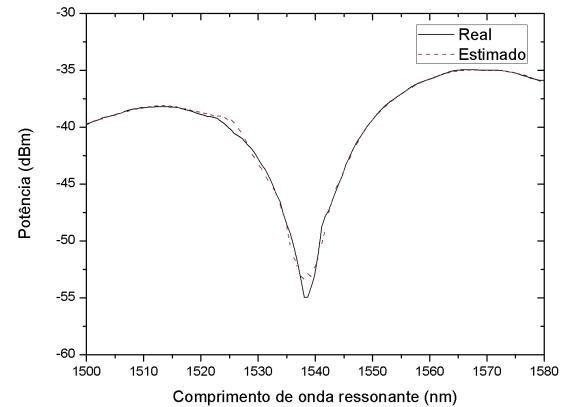


Figura 8: Estimativa obtida para um espectro do banco de dados de teste.

IV. CONCLUSÃO

Pode-se concluir então que o sistema proposto nesse trabalho consegue estimar espectros de transmissão de LPFGs com acurácia próxima à resolução destes, possibilitando utilizar

métodos de interrogação baseados na análise da curva do espectro com custo menor que os métodos utilizados até então.

Além da análise da variação no comprimento de onda ressonante, o método proposto possibilita também a análise de outras variáveis como banda de rejeição da LPFG e profundidade do vale, tornando o sistema de interrogação mais robusto que os métodos baseados em potência que são reportados na literatura.

AGRADECIMENTOS

Agradecemos ao apoio da FAPEMIG, CNPq, Propesq-UFJF e Inerge-UFJF e CPFL Energia.

REFERÊNCIAS

- [1] J. L. Santos and F. Farahi, *Handbook of optical sensors*, 1st ed. CRC Press, 2014.
- [2] T. Erdogan, "Fiber grating spectra," *Journal of Lightwave Technology*, vol. 15, no. 8, pp. 1277–1294, 1997.
- [3] X. Shu, L. Zhang, and I. Bennion, "Sensitivity characteristics of long-period fiber gratings," *Journal of Lightwave Technology*, vol. 20, no. 2, pp. 255–266, 2002.
- [4] B. C. Lee, E.-J. Jung, C.-S. Kim, and M. Y. Jeon, "Dynamic and static strain fiber Bragg grating sensor interrogation with a 1.3 μm fourier domain mode-locked wavelength-swept laser," *Measurement Science and Technology*, vol. 21, no. 9, p. 094008, 2010.
- [5] J. Park, Y. S. Kwon, M. O. Ko, and M. Y. Jeon, "Dynamic fiber bragg grating strain sensor interrogation based on resonance fourier domain mode-locked fiber laser," in *Avionics and Vehicle Fiber-Optics and Photonics Conference (AVFOP), 2016 IEEE*. IEEE, 2016, pp. 291–292.
- [6] H. Patrick, G. Williams, A. Kersey, J. Pedrazzani, and A. Vengsarkar, "Hybrid fiber Bragg grating/long period fiber grating sensor for strain/temperature discrimination," *IEEE Photonics Technology Letters*, vol. 8, no. 9, pp. 1223–1225, 1996.
- [7] G. Kahandawa, J. Epaarachchi, H. Wang, D. Followell, and P. Birt, "Use of fixed wavelength Fibre-Bratt Grating (FBG) filters to capture time domain data from the distorted spectrum of an embedded fbg sensor to estimate strain with an artificial neural network," *Sensors and Actuators A: Physical*, vol. 194, pp. 1–7, 2013.
- [8] M. A. Jucá and A. B. dos Santos, "Fiber Bragg grating interrogation using fbg filters and artificial neural network," in *Microwave and Optoelectronics Conference (IMOC), 2017 SBMO/IEEE MTT-S International*. IEEE, 2017, pp. 1–4.
- [9] F. Murtagh, "Multilayer perceptrons for classification and regression," *Neurocomputing*, vol. 2, no. 5-6, pp. 183–197, 1991.
- [10] F. D. Foressee and M. T. Hagan, "Gauss-Newton approximation to Bayesian learning," in *Neural networks, 1997., international conference on*, vol. 3. IEEE, 1997, pp. 1930–1935.