

[IC] Sensor óptico LPFG para avaliação de intensidade e direção de campo magnético

Felipe Barino*, Daniel Discini†, Thiago Coelho‡ e A. Bessa dos Santos§

Departamento de Circuitos, Universidade Federal de Juiz de Fora

*felipe.barino@engenharia.ufjf.br, †danielsilveira@engenharia.ufjf.br,

‡thiago.coelho@ufjf.edu.br, §alexandre.bessa@engenharia.ufjf.br

Resumo—Nesse trabalho é apresentado um estudo sobre a aplicação da birrefringência induzida pela compressão lateral em um sensor LPFG no sensoriamento de campos magnéticos, como parte de um sistema para evitar aproximação de VANTs à linhas de transmissão. Um modelo de regressão baseado em redes neurais é apresentado e comparado com regressão polinomial por meio de dados estatísticos como Erro Médio Quadrático e R2.

Palavras-chave—sensores ópticos, redes de período longo, sensor magnético, redes neurais, linhas de transmissão

I. INTRODUÇÃO

Os avanços do mercado na área de instrumentação vêm beneficiando o desenvolvimento da tecnologia de sensores ópticos devido ao aumento da oferta de componentes ópticos a um bom custo-benefício e do número de fornecedores [1]. As chamadas Redes de Bragg (Fiber Bragg Grating - FBG) e Redes de Período Longo em Fibra (Long Period Fiber Grating - LPFG) são duas estruturas importantes no sensoriamento por fibra óptica. Ambas são redes de difração escritas dentro da própria fibra por meio da modulação periódica do índice de refração desta.

As Redes de Período Longo em Fibra (LPFGs) são estruturas mais simples de serem fabricadas, quando comparadas às Redes de Bragg, uma vez que sua fabricação pode ser feita em fibras ópticas padrão e também pelo seu período de modulação ser consideravelmente maior. Como consequência do período maior, as LPFGs são redes de transmissão e por isso podem ser consideradas filtros rejeita-faixa. Seu uso como sensor ocorre, pois o comprimento de onda central da banda de rejeição, dado por (1), é função de parâmetros que podem variar de acordo com o ambiente, [2], [3].

$$\lambda_{res}^m = (n_{eff,co} - n_{eff,cl}^m)\Lambda \quad (1)$$

Devido ao tamanho compacto e à imunidade eletromagnética dessa classe de sensores, o uso de sensores ópticos na avaliação de corrente elétrica e campo magnético se mostra promissor. Uma vez que o ambiente onde se deseja medir tais grandezas são altamente influenciados por campos eletromagnéticos, gerando ruído e erros de medições em sensores que utilizam sinais elétricos para transmissão dos dados. Em [4] um sensor baseado em FBG capaz de medir simultaneamente temperatura e corrente elétrica é apresentado, já [5] utiliza uma LPG cercada por líquido magnético para fabricação de um filtro variável e [6] um sensor FBG de




Figura 1. Esquema da aplicação do sensor em um VANT para estimativa de sua posição em relação a uma linha de transmissão.

campo magnético através da deformação física induzida na fibra pela aplicação de campo magnético em um composto magnetostrictivo.

Esse trabalho apresenta um estudo sobre a birrefringência em LPFGs induzida por cargas laterais, aplicadas por uma haste acoplada a um ímã. Esse conjunto pode ser acoplado a um VANT (Veículo Aéreo Não Tripulado) para evitar que o mesmo se aproxime de linhas de transmissão, como ilustrado na Figura 1. O ímã acoplado à esta haste é perturbado por uma força \vec{F} , força essa que surge pela influência do campo magnético induzido pela corrente elétrica que flui no cabo condutor da linha de transmissão. Essa força é transmitida à LPFG pela haste conforme ilustrado na Figura 2. Note que a torção na haste, gerada por \vec{F} , pressiona a LPFG com o mesmo ângulo θ entre o cabo e o VANT (ver Figura 1).

Para estudar esse sistema foram simuladas situações com diferentes intensidades de forças, com diversos ângulos de atuação. As grandezas intensidade da força e ângulo de atuação foram então estimadas por uma rede neural. Os resultados da rede são então comparados com uma regressão polinomial.




Figura 2. Atuação da força exercida pela haste na LPFG. As variáveis de interesse, \vec{F} e θ , para estimativa da posição do VANT em relação à linha de transmissão estão destacadas.

II. METODOLOGIA

A. Modelo do sensor

Um dos efeitos da ação de uma carga transversal em uma LPFG é o aumento da birrefringência na mesma, levando à separação de cada modo propagante em dois, relacionados aos dois eixos principais de polarização, [7]. Porém as grades escritas pelo método de descargas elétricas, como as produzidas pelo LITel, já possuem birrefringência, induzida pelo próprio processo de fabricação, [8]. Essa segunda assimetria ocorre ao receber a descarga elétrica, causando variações de até $\Delta n \approx 2 \cdot 10^{-3}$ no índice de refração [9], porém devido à exposição unilateral da fibra à descarga elétrica, essa variação não é uniforme ao longo da seção transversal da fibra, causando assim a birrefringência. Logo os comprimentos de onda ressonante, nos eixos principais de polarização, são dados por [8]:

$$\lambda_{res}^{max} = \Lambda(\Delta n^{min}) \quad (2)$$

$$\lambda_{res}^{min} = \Lambda(\Delta n^{max}) \quad (3)$$

Já a birrefringência induzida pela aplicação de cargas laterais pode ser calculada pela variação do índice de refração em cada eixo de polarização, as equações do chamado efeito foto-elástico são:

$$\Delta n_x = -\frac{(n_{eff}^3)}{2E}((p_{11} - 2\nu p_{12})\sigma_x + ((1 - \nu)p_{12} - \nu p_{11})(\sigma_y + \sigma_z)) \quad (4)$$

$$\Delta n_y = -\frac{(n_{eff}^3)}{2E}((p_{11} - 2\nu p_{12})\sigma_y + ((1 - \nu)p_{12} - \nu p_{11})(\sigma_x + \sigma_z)) \quad (5)$$

Onde E , ν e p_{ij} são respectivamente o módulo de Young, o coeficiente de Poisson e os componentes do tensor fotoelástico. Para a sílica esses parâmetros são: $E = 74.52$ GPa, $\nu = 0.17$, $p_{11} = 0.121$ e $p_{12} = 0.270$.

Considerando um sensor devidamente encapsulado, em que uma força F aplicada a ele pode ser considerada como uma distribuição linear e constante ao longo de todo o comprimento L da grade, e que esta faz um ângulo θ com o eixo-y de polarização da fibra de raio b , os estresses σ_x e σ_y nos eixos de polarização da fibra são dados por:

$$\sigma_x = \frac{F}{\pi L b}(\cos(\theta) - 2 \sin(\theta)) \quad (6)$$

$$\sigma_y = \frac{F}{\pi L b}(\sin(\theta) - 2 \cos(\theta)) \quad (7)$$

Já os efeitos da deformação física são calculados pela variação no período da grade:

$$\Lambda = \Lambda_0(1 + \frac{1}{E}(\sigma_z - \nu(\sigma_x + \sigma_y))) \quad (8)$$

Com o uso das equações (4) a (8) pode-se modelar os efeitos de forças laterais na LPFG. A caracterização do sensor constituído por uma LPFG escrita em fibra SMF28 com período $\Lambda = 470 \mu\text{m}$ foi realizada através da colocação de pesos variando entre 1 kg e 5 kg com diferentes ângulos de atuação.

B. Interrogação

Propõe-se aqui discutir a interrogação do sistema por meio da análise do comprimento de onda ressonante utilizando redes neurais. Uma rede neural é um modelo computacional cujo funcionamento é inspirado no sistema nervoso central de animais. Esse modelo consiste em um conjunto de unidades, chamadas de neurônios artificiais, interconectadas e é capaz de mapear valores de entradas em valores de saída com base em exemplos que o sistema aprendeu durante a fase de aprendizado.

Um neurônio artificial, assim como o biológico, processa informação e a transmite para outros neurônios. Esse processamento consiste na aplicação da combinação linear das entradas do neurônio em uma função, chamada função de ativação, a determinação destes coeficientes ocorre durante o treinamento da rede.

A topologia de redes neurais escolhida foi o MLP (Multi-layer perceptron), esta é capaz de mapear, quando devidamente treinada, um grupo de entradas em um grupo de saídas, sendo assim ela realiza a regressão de uma dada função [10]. O sistema em si foi desenvolvido em python com auxílio da biblioteca scikit-learn.

III. RESULTADOS

A. Caracterização

O sensor LPFG foi submetido à diferentes cargas variando de 0 kg a 5 kg, também foi variado o ângulo entre a normal da carga e o eixo de polarização y da fibra, tal variação

ocorreu para uma volta completa com intervalo de 15 deg, como esquematizado na Figura 3.




Figura 3. Esquema do setup utilizado para caracterização do sensor.

Ao observar o comportamento dos comprimentos de onda ressonante em relação à variação da intensidade da carga, para ângulos fixos, pode-se notar que o aumento da carga a qual o sensor LPFG é submetido, causa aumento na separação entre $\lambda_{res,x}$ e $\lambda_{res,y}$, como ilustrado na Figura 4. Esse tipo de comportamento ocorre, pois quando F cresce, σ_x também cresce ao passo que σ_y diminui, levando ao aumento da birrefringência e, conseqüentemente, ao aumento da separação entre os comprimentos de onda ressonante.

Já para uma carga fixa, com o ângulo variando, nota-se um comportamento periódico no vale de ressonância, de fato, ao aplicar as equações (6) e (7) às equações (4) e (5) tem-se que a variação do índice de refração é uma função senoidal. Também nota-se que os vales nos eixos de polarização ortogonais não apresentam simetria quando o sensor é rotacionado em 180° . Esse fato se deve à birrefringência induzida pelo processo de fabricação do sensor, como cada eixo de polarização apresenta um índice médio a variação no índice de refração em cada um dos eixos ocorre de maneira ligeiramente diferente.




Figura 4. Relação entre ângulo de atuação/intensidade da carga e comprimento de onda ressonante.

B. Interrogação

Os pontos da Figura 4 foram aleatoriamente divididos em grupo de treino(85%) e teste(15%) para a análise da rede neural. Esta possui uma camada de entrada, uma escondida e uma de saída. A camada escondida foi configurada com 35 neurônios possuindo função de ativação ReLU, definida pela equação (9). Já a camada de saída é uma função identidade, que é em termos práticos igual à nenhuma função de ativação, desta forma a saída do sistema pode assumir praticamente qualquer valor real e possibilita à rede neural realizar a regressão de uma função qualquer. O algoritmo de treinamento utilizado foi o LBFGS com taxa de aprendizado igual a 10^{-5} , esse método foi escolhido por ter menor custo computacional quando comparado ao método do Gradiente Descendente.

$$\Phi(x) = \begin{cases} 0 & x < 0 \\ x & x \geq 0 \end{cases} \quad (9)$$

Além do MLP, um polinômio de grau quatro de $\mathbb{R}^2 \rightarrow \mathbb{R}$ foi ajustado, a fim de comparação. A performance de ambos foi comparada qualitativamente através das retas de regressão e quantitativamente por meio do Erro Médio Quadrático (EMQ) e do coeficiente de determinação (R^2). Nesse comparação, um bom modelo deve possuir EMQ tão próximo de zero quanto possível, indicando que os resultados obtidos se aproximam do real. Mas também deve apresentar um R^2 perto da unidade, indicando que o modelo consegue explicar os valores observados.

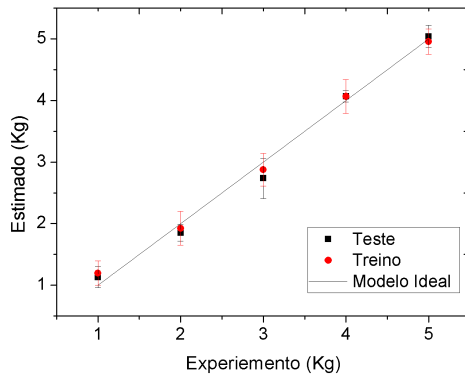
Outro fator que indica qualidade do sistema de interrogação é a pouca diferença entre as estatísticas dos grupos de treinamento e teste. Uma vez que o grupo de treino foi utilizado para o ajuste do modelo aos dados observados este tende a ter melhor performance quando comparado ao grupo de teste, logo se os dados estatísticos para o grupo de teste é próximo aos dados do grupo de treinamento, o modelo apresenta uma boa generalização. De fato, pois mesmo sem ter acesso aos dados de teste o modelo realiza a regressão tão bem quanto para os dados já vistos. Sabendo disso o desempenho de cada método pode ser quantitativamente avaliado pelos dados tabelados abaixo.

Tabela I
PERFORMANCE DA REGRESSÃO POLINOMIAL.


	Carga		Ângulo	
	Treino	Teste	Treino	Teste
EMQ	0.0706	0.0388	2924	2822
R^2	0.9632	0.9813	0.6386	0.5516

Tabela II
PERFORMANCE DA REGRESSÃO POR REDE NEURAL.

	Carga		Ângulo	
	Treino	Teste	Treino	Teste
EMQ	0.04267	0.2046	724.3	811.5
R^2	0.9785	0.8972	0.9342	0.9263




(a)

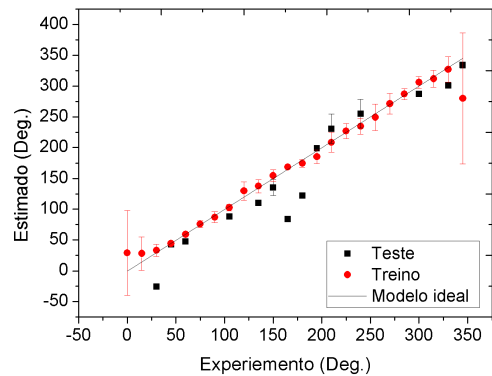


(b)

Figura 5. Relação Experimento-Estimativa para o modelo polinomial.



(a)



(b)

Figura 6. Relação Experimento-Estimativa para a Rede Neural.

Dos resultados mostrados nas Tabelas I e II nota-se que a rede neural obteve um bom resultado, com coeficiente de terminação próximo à unidade e baixo erro médio quadrático, quando comparado à regressão polinomial. E o mais importante, esses resultados também se apresentam com poucas discrepâncias entre os subgrupos de treino e teste, indicando que o sistema de interrogação possui boa capacidade de generalização.

As Figuras 5 e 6 mostram as retas de regressão para os dois modelos comparados, tanto para intensidade da carga quanto para ângulo de atuação da mesma. Vale ressaltar que para cada valor de carga existem 12 valores de ângulo de atuação e, consequentemente, para cada ângulo existem cinco cargas. Por esse motivo, as possíveis variações que possam existir para valores constantes de carga ou ângulo estão representadas pelas barras de erro.

Note que para a regressão polinomial os erros estão mais distribuídos ao longo de todo o banco de dados, com erros maiores para ângulos de atuação próximos à origem (0° e 360°). Já para a rede neural, os erros acontecem majoritariamente na origem, esse fato pode ser associado à natureza periódica do problema e pode ser contornado aumentando o banco de dados, acrescentando novos valores de ângulo, entre $[-45^\circ, 0^\circ)$

e $(360^\circ, 405^\circ]$ e limitando a função de ativação linear da saída para $[0^\circ, 360^\circ]$, por exemplo.

IV. CONCLUSÃO

Esse trabalho explora uma área do sensoriamento ainda pouco utilizada em aplicações de robótica, que tem o potencial de aumentar as possibilidades de sensoriamento de forças, introduzindo a possibilidade de medir tanto intensidade quanto a direção da força aplicada. E, neste caso, atuar como sensor para estimativa da posição relativa entre um VANT e uma linha de transmissão.

O método de regressão por rede neural se mostrou uma boa alternativa ao método mais convencional de regressão polinomial, apesar de ainda manter erros na origem da circunferência, que como proposto, pode ser reduzido com o aumento do banco de dados.

Com isso conclui-se que o método de sensoriamento por meio da análise de birrefringência em sensores LPFG possui um grande potencial para a fabricação de sensores bidirecionais de forças, e sua aplicação no posicionamento de veículos autônomos.

AGRADECIMENTOS

Agradecemos ao apoio da FAPEMIG, CNPq, Propesq-UFJF, Inerge-UFJF e CPFL Energia.

REFERÊNCIAS

- [1] J. L. Santos and F. Farahi, *Handbook of optical sensors*, 1st ed. CRC Press, 2014.
- [2] T. Erdogan, "Fiber grating spectra," *Journal of Lightwave Technology*, vol. 15, no. 8, pp. 1277–1294, 1997.
- [3] X. Shu, L. Zhang, and I. Bennion, "Sensitivity characteristics of long-period fiber gratings," *Journal of Lightwave Technology*, vol. 20, no. 2, pp. 255–266, 2002.
- [4] D. Reilly, A. J. Willshire, G. Fusiek, P. Niewczas, and J. R. McDonald, "A fiber-Bragg-grating-based sensor for simultaneous AC current and temperature measurement," *IEEE Sensors Journal*, vol. 6, no. 6, pp. 1539–1542, 2006.
- [5] T. Liu, X. Chen, Z. Di, J. Zhang, X. Li, and J. Chen, "Tunable magneto-optical wavelength filter of long-period fiber grating with magnetic fluids," *Applied Physics Letters*, vol. 91, no. 12, p. 121116, 2007.
- [6] H. Liu, S. W. Or, and H. Y. Tam, "Magnetostrictive composite-fiber bragg grating (MC-FBG) magnetic field sensor," *Sensors and Actuators A: Physical*, vol. 173, no. 1, pp. 122–126, 2012.
- [7] L. Zhang, Y. Liu, L. Everall, J. Williams, and I. Bennion, "Design and realization of long-period grating devices in conventional and high birefringence fibers and their novel applications as fiber-optic load sensors," *IEEE Journal of Selected Topics in Quantum Electronics*, vol. 5, no. 5, pp. 1373–1378, 1999.
- [8] B. L. Bachim and T. K. Gaylord, "Polarization-dependent loss and birefringence in long-period fiber gratings," *Applied optics*, vol. 42, no. 34, pp. 6816–6823, 2003.
- [9] B. Sévigny, M. Leduc, M. Faucher, N. Godbout, and S. Lacroix, "Characterization of the large index modification caused by electrical discharge in optical fibers," in *Conference on Lasers and Electro-Optics*. Optical Society of America, 2009, p. JTuD72.
- [10] F. Murtagh, "Multilayer perceptrons for classification and regression," *Neurocomputing*, vol. 2, no. 5-6, pp. 183–197, 1991.