

08 a 11 de Outubro de 2019
Universidade Federal de Juiz de Fora
Juiz de Fora - MG

SENSOR ÓPTICO DE TATO APLICADO A EFETUADORES ROBÓTICOS UTILIZANDO LPGS E REDES NEURAS ARTIFICIAS

Felipe Oliveira Barino¹ - felipe.barino@engenharia.ufjf.br

Mário Eurípedes²

Eduardo Tinti²

Alexandre Bessa¹ - alexandre.bessa@engenharia.ufjf.br

¹Universidade Federal de Juiz de Fora, Juiz de Fora, MG, Brasil

²Santo Antônio Energia, Rondônia, RO, Brasil

Resumo. *Este trabalho apresenta a utilização de Redes de Período Longo no sensoriamento de forças bidirecionais, como sensor de tato em um efetuador robótico. Melhorias com relação a proposta anterior são apresentadas no âmbito do treinamento da rede neural utilizada para discriminar as forças envolvidas no toque.*

Palavras-chave: *sensores ópticos, redes de período longo, sensor de tato, sensor de força, rede neural*

1. INTRODUÇÃO

Sensores ópticos fabricados em fibra óptica têm ganhado espaço na área de instrumentação nos últimos anos, Santos (2014) atribui esse aumento aos avanços do mercado na área de telecomunicações, que levaram a um aumento no número de fornecedores e na oferta de componentes ópticos com um bom custo-benefício. As chamadas Redes de Bragg (Fiber Bragg Grating - FBG) e Redes de Período Longo em Fibra (Long Period Fiber Grating - LPG) são duas estruturas importantes no sensoriamento por fibra óptica. Ambas são redes de difração escritas dentro da fibra óptica por meio de um processo de modulação do índice de refração desta.

As Redes de Período Longo em Fibra (LPGs) são estruturas mais simples de serem fabricadas, quando comparadas às Redes de Bragg, uma vez que sua fabricação pode ser feita em fibras ópticas padrão e também pelo seu período de modulação ser consideravelmente maior. Como consequência do período de modulação maior, as LPGs são estritamente redes de transmissão e por isso podem ser consideradas filtros rejeita-faixa. Assim, seu uso como sensor ocorre, pois o comprimento de onda central, denotado por λ_{res}^m , é função de parâmetros que variam com o ambiente. Esses parâmetros são: o índice de refração do núcleo $n_{eff,co}$, da casca $n_{eff,cl}$ e também o período Λ da LPG, Erdogan (1997); Shu et al (2002). Essa relação é dada por:

$$\lambda_{res}^m = (n_{eff,co} - n_{eff,cl}^m)\Lambda \quad (1)$$

Por serem compactos, leves, fáceis de multiplexar e imunes à interferência eletromagnética, esses sensores vêm ganhando espaço na literatura quando se trata de sistemas autônomos e robóticos. Park et al (2007) apresentam um sensor de forças baseado em FBGs em um dedo robótico capaz de medir forças de até 0.01 N e também a localização desta. Já Franke et al (2009) utiliza FBGs em manipuladores robóticos, porém como sensor na malha de realimentação do sistema, para controle de vibração do mesmo. Outro sensor que pode ser utilizado em sistemas de controle é apresentado por Delgado et al (2016), os autores reportam um sensor de corrente elétrica para aferir corrente em motores de quadrotoros.

Porém os sensores de deformação citados acima exploram majoritariamente os efeitos da deformação longitudinal na fibra óptica, aumentando consideravelmente o número de sensores necessários para o sistema ser eficaz em termos multidimensionais. Ao passo que, analisando os efeitos de birrefringência causados por deformações laterais na fibra óptica, pode-se criar sensores capazes de medir forças em duas dimensões, como o sensor FBG de campos bidimensionais de stress estudado por Bosia et al (2003), e até mesmo em três dimensões como os desenvolvidos por Mawatari & Nelson (2008) e Zhou et al (2012). Para LPGs um estudo da variação do espectro, devido à birrefringência induzida pela aplicação de uma carga lateral no dispositivo é apresentado por Zhang et al (1999). Já Wang et al (2007) estudam a variação do ângulo de aplicação da carga lateral e o impacto no espectro de transmissão do dispositivo.

Barino & Santos (2018) apresentam um estudo sobre a birrefringência em LPGs devido à aplicação de cargas laterais em diferentes ângulos, para aplicação semelhante à apresentada neste trabalho e ilustrada na Figura 1, mostrando que a discriminação das forças envolvidas no contato do efetuador com o objeto manipulado pode ser realizada por uma rede neural artificial. Porém consideram-se todos os ângulos possíveis na geometria da fibra no desenvolvimento da rede neural. Sendo o objetivo do sensor mensurar a intensidade e a direção de contato do efetuador com um objeto, a própria natureza do problema restringe o ângulo θ de aplicação da força externa F entre 0 deg e 180 deg. Este trabalho, apresenta um ajuste fino no sistema proposto, restringindo os ângulos de atuação aos intervalos coerentes com a aplicação.




Figura 1- Uso do sensor LPG para avaliação da intensidade e direção de contato em um manipulador robótico.

2. METODOLOGIA

2.1 Modelo do sensor

Um dos efeitos da ação de uma carga transversal em uma LPG é o aumento da birrefringência na mesma, levando à separação de cada modo propagante em dois, relacionados aos dois eixos principais de polarização, Zhang et al (1999). Porém as grades escritas pelo método de descargas elétricas (método utilizado nas redes fabricadas pelo LITel-UFJF) já possuem birrefringência, induzida pelo próprio processo de fabricação, Bachim & Gaylord (2003). Durante esse processo, a descarga elétrica induz uma variação no índice de refração na ordem de $\Delta n \approx 2 \cdot 10^{-3}$, Sévigny et al (2009). Porém, devido à exposição unilateral da fibra à descarga, essa variação não é uniforme em todos os ângulos da seção transversal da fibra, ou seja, o dispositivo se torna sensível à polarização de entrada. Sendo assim os comprimentos de onda ressonantes, nos eixos principais de polarização, são dados por, Bachim & Gaylord (2003):

$$\lambda_{res}^{max} = \Lambda(\Delta n^{min}) \quad (2)$$

$$\lambda_{res}^{min} = \Lambda(\Delta n^{max}) \quad (3)$$

Já a birrefringência induzida pela aplicação de cargas laterais pode ser calculada pela variação do índice de refração em cada eixo de polarização, denotada por Δn_x para o eixo x e Δn_y para o eixo y. As equações do chamado efeito foto-elástico são:

$$\Delta n_x = -\frac{(n_{eff}^3)}{2E}((p_{11} - 2\nu p_{12})\sigma_x + ((1 - \nu)p_{12} - \nu p_{11})(\sigma_y + \sigma_z)) \quad (4)$$

$$\Delta n_y = -\frac{(n_{eff}^3)}{2E}((p_{11} - 2\nu p_{12})\sigma_y + ((1 - \nu)p_{12} - \nu p_{11})(\sigma_x + \sigma_z)) \quad (5)$$

Onde E , ν e p_{ij} são respectivamente o módulo de Young, o coeficiente de Poisson e os componentes do tensor fotoelástico. Para a sílica esses parâmetros são: $E = 74.52$ GPa, $\nu = 0.17$, $p_{11} = 0.121$ e $p_{12} = 0.270$. Já os termos σ_x , σ_y e σ_z são os estresses na fibra, tratados com detalhes a seguir.

Considerando um sensor devidamente encapsulado, esquematizado na Figura 2, em que uma força F aplicada a ele pode ser considerada como uma distribuição linear e constante ao longo de todo o comprimento L da grade, e que esta faz um ângulo θ com o eixo-y de polarização da fibra de raio b , os estresses σ_x e σ_y nos eixos de polarização da fibra são obtidos a partir da sobreposição dos dois casos ilustrados na Figura 3 e são dados pelas equações 6 e 7:

$$\sigma_x = \frac{F}{\pi L b}(\cos(\theta) - 2 \sin(\theta)) \quad (6)$$

$$\sigma_x = \frac{F}{\pi L b} (\sin(\theta) - 2 \cos(\theta)) \quad (7)$$




Figura 2- Aplicação de uma força F em um sensor LPG.




Figura 3- Decomposição dos estresses em relação aos eixos de polarização da fibra: σ_{x, F_x} e σ_{y, F_x} para a componente de força F_x paralela ao eixo x de polarização e σ_{x, F_y} e σ_{y, F_y} para a componente F_y .

Já os efeitos da deformação física são calculados pela variação no período da grade, seja Λ_0 o período da grade sem sofrer deformação:

$$\Lambda = \Lambda_0 \left(1 + \frac{1}{E} (\sigma_z - \nu(\sigma_x + \sigma_y)) \right) \quad (8)$$

Com o uso das equações 4 a 8 pode-se modelar os efeitos de forças laterais na LPG. A caracterização do sensor constituído por uma LPG escrita em fibra SMF28 com período

$\Lambda = 470 \mu\text{m}$ foi realizada através da colocação de pesos variando entre 1 kg e 5 kg com diferentes ângulos de atuação.

2.2 Interrogação

Como discutido anteriormente, as LPGs podem ser utilizadas como sensores, pois seu comprimento de onda ressonante varia com parâmetros externos. Portanto, no desenvolvimento de sensores baseados nestes dispositivos deve-se correlacionar o comprimento de onda ressonante com o mensurando, em instrumentação óptica, este processo é chamado de interrogação. Esta seção discute a interrogação do sistema por meio da análise do comprimento de onda ressonante utilizando redes neurais. Uma rede neural (RN) é uma ferramenta de modelagem computacional inspirada no funcionamento do cérebro humano. A arquitetura padrão de uma RN consiste em um conjunto de unidades de processamento, denominadas neurônios artificiais, dispostas em camadas que, por sua vez, são interconectadas. Através do processamento massivo e paralelo realizado pelos neurônios sobre o sinal de entrada enquanto este transita até a camada de saída, a RN aprende a mapear valores de entradas em valores de saída com base em um conjunto de pares entrada-saída utilizado para treiná-la durante a fase de aprendizado.

A propagação de sinais através de uma RN é, na maioria dos casos, do tipo *feedforward* e, resumidamente, acontece da seguinte forma:

- Os sinais de entrada dos neurônios artificiais alocados em uma camada da RN são gerados por uma combinação linear dos sinais de saída dos neurônios alocados na camada imediatamente anterior.
- Essas entradas são então processadas por cada neurônio através de suas funções de ativação para gerar as respectivas saídas.
- Com essas saídas o processo se repete em relação à camada seguinte até que se chegue à última camada da RN ou camada de saída.

Os pesos utilizados nas combinações lineares são inicializados de acordo com algum critério escolhido e, durante a fase de treinamento, são atualizados de modo a minimizar o erro de saída da RN.

A rede neural utilizada foi o MLP (Multilayer perceptron), capaz de realizar a regressão de uma função, quando devidamente treinada, Murtagh (1991). O sistema em si foi desenvolvido em python com auxílio da API scikit-learn, Buitinck et al (2013). Uma rede neural foi desenvolvida para estimativa da carga aplicada à LPG e outra para estimativa do ângulo que esta carga foi aplicada. Onde a primeira recebe como entrada os comprimentos de onda ressonantes dos dois eixos de polarização, $\lambda_{res,x}$ e $\lambda_{res,y}$, e tem como saída a carga a qual o sensor é submetido, e a segunda tem como entrada os mesmos comprimentos de onda, mas tem como saída o ângulo de aplicação.

3. RESULTADOS

3.1 Resposta do sensor

Primeiramente foi observada a resposta da LPG à compressão por cargas variando de 0 kg a 5 kg, com intervalo de 1 kg. Os espectros para a LPG sem carga e carregada com 5 kg podem ser vistos na Figura 4, na qual estão representadas as potências ópticas dos espectros de

transmissão: em preto da LPG, em vermelho do eixo x de polarização e em azul do eixo y de polarização.

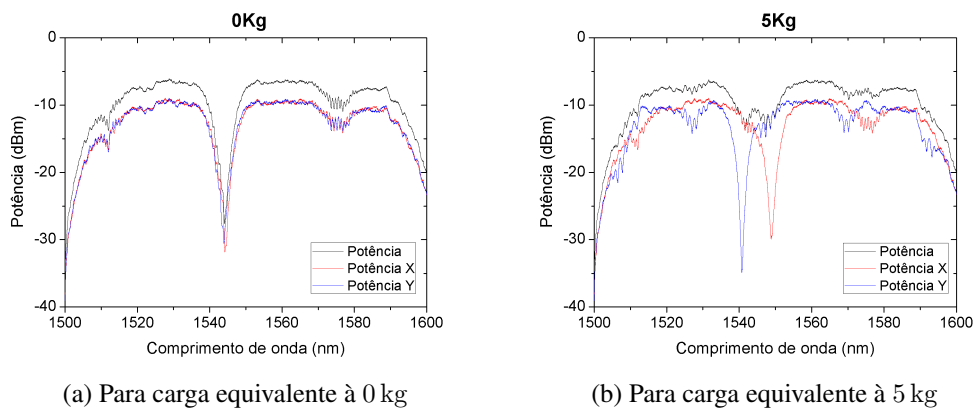


Figura 4- Espectros obtidos na caracterização do sistema.

Pode-se notar que com o aumento da carga à qual o sensor LPG é submetido, a separação entre $\lambda_{res,x}$ e $\lambda_{res,y}$ também aumenta. Esse tipo de comportamento ocorre, pois quando F cresce, σ_x também cresce ao passo que σ_y diminui, levando ao aumento da birrefringência e, consequentemente, ao aumento da separação entre os comprimentos de onda ressonantes.

Em seguida a LPG foi rotacionada de $\theta = 0^\circ$ a $\theta = 180^\circ$, em 13 etapas, para cada uma das cargas citadas anteriormente. Nesse caso nota-se um comportamento periódico no vale de ressonância: de fato, ao aplicar as equações 6 e 7 às equações 4 e 5 nota-se que a variação do índice de refração é uma função senoidal. Veja, na Figura 5 que essas senoides possuem amplitude que dependem da intensidade da carga.


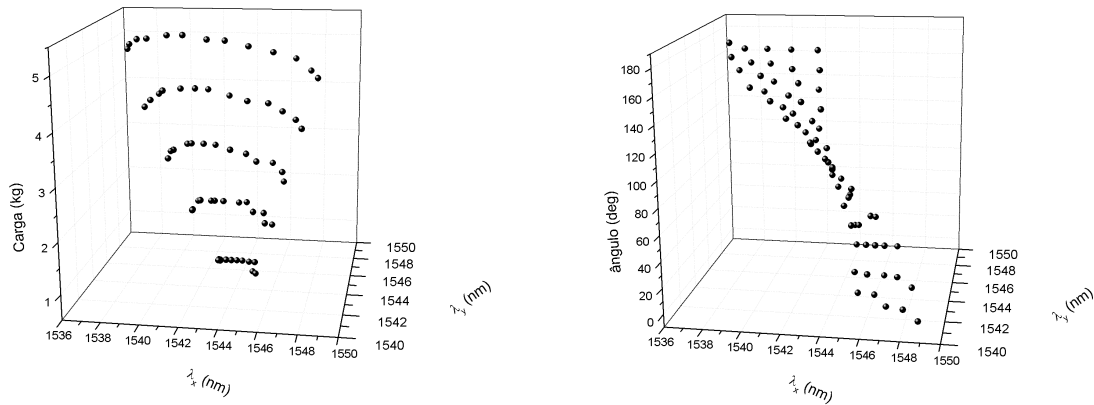


Figura 5- Relação entre ângulo de atuação/intensidade da carga e comprimento de onda ressonante.

3.2 Interrogação

A fim de utilizar a LPG modelada como um sensor, esta foi caracterizada conforme o método de interrogação proposto. Os pontos da Figura 5 foram utilizados para o projeto das redes neurais que serão utilizadas para estimar a intensidade da força e o ângulo de atuação, separadamente. As redes utilizadas possuem uma camada de entrada, uma escondida e uma de saída. Em cada uma destas RNs, a camada de entrada é alimentada com os comprimentos de onda ressonante em cada eixo de polarização da fibra, portanto a camada de entrada e saída possuem 2 e 1 neurônios, respectivamente, e realizam a regressão dos pontos mostrados em cada gráfico da Figura 6.



(a) Relação entre comprimentos de onda ressonante e carga.

(b) Relação entre comprimentos de onda ressonante e ângulo.

Figura 6- Relação entrada/saída das RNs utilizadas para estimativa da carga (a) e ângulo de aplicação (b).

Já a camada escondida, foi configurada com base em uma seleção de modelo realizada por Validação Cruzada, utilizando o método *K-folds*. A análise por meio de Validação Cruzada é crucial para o desenvolvimento de sistemas de inteligência artificial, pois avalia a capacidade de generalização Kohavi et al (1995). Os neurônios desta camada foram configurados com função de ativação ReLU, dada por:

$$\Phi(x) = \begin{cases} 0 & x < 0 \\ x & x \geq 0 \end{cases} \quad (9)$$

A camada de saída, por outro lado, possui função de ativação identidade, que é em termos práticos, equivalente a nenhuma função de ativação. Desta forma, a saída de cada uma das RNs pode assumir praticamente qualquer valor real e possibilita às elas realizar a regressão de funções. O algoritmo de treinamento utilizado foi o ADAM Kingma & Ba (2014), desenvolvido especialmente para ser aplicado em problemas de inteligência artificial, a escolha do método nesse caso se dá pela rápida convergência e boa performance no treinamento de *Multi Layer Perceptrons*, como apresentado pelos autores no estudo.

O *K-folds* foi realizado com cinco dobras no banco de dados para 18 números de neurônios na camada escondida, de cada rede neural, variando igualmente de 2 a 70 neurônios. Os resultados obtidos para as redes neurais que realizam a regressão da intensidade da força e do ângulo

de aplicação são mostrados na Figura 7, na qual os MSEs (*Mean Squared Errors*) obtidos nas cinco dobras, para as partições de teste do banco de dados.

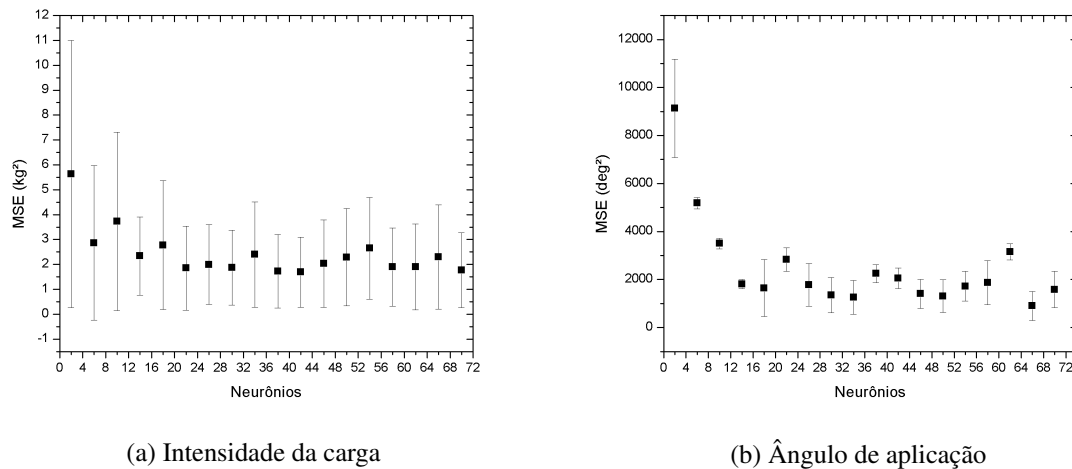


Figura 7- Resultados da seleção do número de neurônios da camada escondida..

Note que para a rede neural que realiza a regressão da intensidade da força, um número de neurônios maior que 22 não apresenta melhoras significativas na fatia do dados usada para teste. Já para a regressão do ângulo, 30 neurônios bastam para tal. O resultado final das redes neurais utilizadas para regressão dos dados, ilustrados na Figura 6, foram obtidos para estes tamanhos de camada oculta com: 85% dos dados para treino e 15% para teste, e analisado pelas retas de regressão mostradas na Figura 8.

Essas retas representam a relação valor real vs valor estimado pela rede neural, nos eixos x têm-se os valores reais (referência), enquanto os eixos y representam os valores estimados. Note que a reta identidade indica a regressão perfeita pelo modelo (mostrada pela linha preta). Vale ressaltar também que, para cada valor constante de carga disponível no banco de dados, existem 13 valores de ângulo de atuação, veja que em cada um dos cinco planos constantes na Figura 6a existem 13 pontos que indicam estes diferentes ângulos. Analogamente, para cada valor constante de ângulo no banco de dados, existem 5 valores de carga, veja que em cada um dos 13 planos constantes na Figura 6b existem 5 pontos que indicam as diferentes cargas. Por esse motivo, as possíveis variações que possam existir para valores constantes de carga ou ângulo, em cada uma das RNs, estão representadas pelas barras de erro.

Observando as Figuras 8a e 8b, nota-se um bom ajuste dos dados obtidos à reta unitária. De fato, em 8a obtém-se $y = 0,9026x + 0,3169$ para o sub grupo de treino com $R^2 = 0,9981$ e, para o sub grupo de teste $y = 0,8329x + 0,4105$ com $R^2 = 0,9803$. Já em 8b obtém-se: $y = 0,92901x + 8,420$ com $R^2 = 0,9868$ para o grupo de treino e $y = 1,011x - 2,970$ com $R^2 = 0,9838$ para o sub grupo de teste. Note que, o erro na regressão do ângulo tende a aumentar próximo aos ângulos $\theta = 0 \text{ deg}$ e $\theta = 180 \text{ deg}$, com os pontos se afastando da reta unitária. Considerando a aplicação proposta, porém, os ângulos mais importantes (à frente do efetuador $\theta \approx \theta = 90 \text{ deg}$) são mais próximo à esta reta.

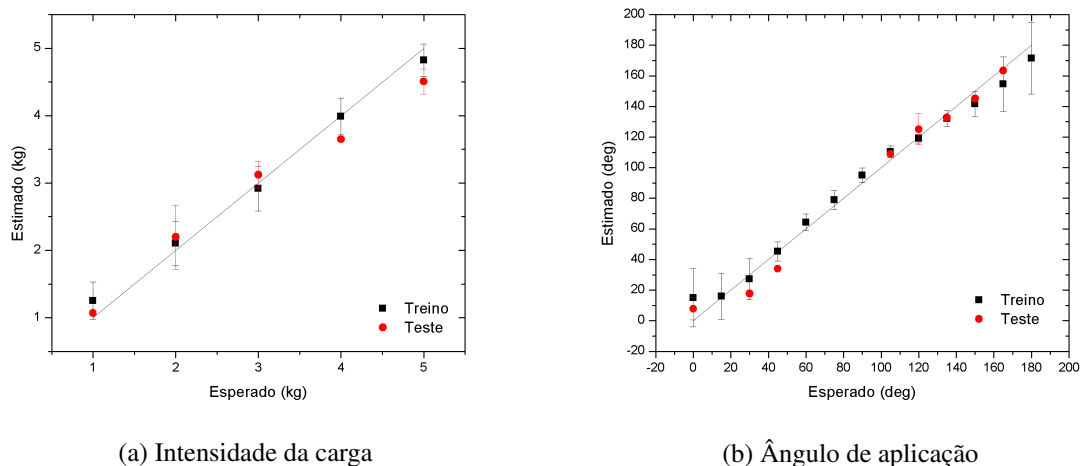


Figura 8- Curvas de regressão para o modelo de interrogação proposto.

Comparando os resultados obtidos por Barino & Santos (2018) com os mostrados nesta seção conclui-se que, de fato, ao restringir os ângulos de atuação da força para o intervalo de interesse durante o treinamento da rede neural, a qualidade do modelo melhora. Analisado o coeficiente de determinação, R^2 , obtido em ambos os trabalhos, pode-se notar que o modelo aqui apresentado realiza melhor a regressão dos dados. Enquanto 98,03% dos dados do grupo de teste para intensidade da força aplicada são bem explicados pelo modelo proposto neste trabalho, apenas 89,72% são explicados pelo trabalho apresentado por Barino & Santos (2018). O mesmo ocorre para o ângulo de aplicação dessa força, com 98,38% no modelo apresentado aqui e 92,63% no trabalho anterior.

4. CONCLUSÃO

Esse trabalho explora uma área do sensoriamento por fibra óptica ainda pouco utilizada em aplicações de robótica e automação que tem o potencial de aumentar as possibilidades de sensoriamento de forças, introduzindo a possibilidade de medir tanto intensidade quanto a direção na qual a força é aplicada com o uso de um único sensor à fibra óptica.

O método de regressão por rede neural se mostrou uma boa alternativa para identificação da intensidade e direção da força aplicada à ponta do efetuator acoplado ao manipulador robótico, com base nos comprimentos de onda ressonantes da LPG. Além do mais, o refinamento do modelo por meio da restrição do banco de dados é capaz de melhorar a qualidade do modelo de regressão. Com isso conclui-se que o método de sensoriamento por meio da análise de birrefringência em sensores LPG possui um grande potencial para a fabricação de sensores bidirecionais de forças, devido à capacidade de determinar não só a intensidade da mesma, mas também a direção. Sendo necessário, em caso de aplicações práticas, a calibração do mesmo com um banco de dados coerente com a aplicação em questão.

Agradecimentos

Agradecemos ao apoio da FAPEMIG, CNPq, Propesq-UFJF, Inerge-UFJF e Santo Antônio Energia.

REFERÊNCIAS

- Bachim, B. L., & Gaylord, T. K. (2003). Polarization-dependent loss and birefringence in long-period fiber gratings. *Applied optics*, 42(34), 6816-6823.
- Barino, F. O. & dos Santos, A. B. (2018), “Sensor óptico LPG para avaliação de forças bidirecionais”, *XXII Congresso Brasileiro de Automática*, João Pessoa, Brasil.
- Bosia, F., Giaccari, P., Botsis, J., Facchini, M., Limberger, H. G., & Salathé, R. P. (2003). Characterization of the response of fibre Bragg grating sensors subjected to a two-dimensional strain field. *Smart materials and Structures*, 12(6), 925.
- Buitinck, L., Louppe, G., Blondel, M., Pedregosa, F., Mueller, A., Grisel, O., & Layton, R. (2013). “API design for machine learning software: experiences from the scikit-learn project”. *European Conference on Machine Learning and Principles and Practices of Knowledge Discovery in Databases*, (arXiv:1309.0238).
- Delgado, F., Carvalho, J., Coelho, T., & Dos Santos, A. (2016). An optical fiber sensor and its application in UAVs for current measurements. *Sensors*, 16(11), 1800.
- Erdogan, T. (1997). Fiber grating spectra, *Journal of Lightwave Technology* 15(8): 1277-1294.
- Franke, R., Malzahn, J., Nierobisch, T., Hoffmann, F., & Bertram, T. (2009, May). “Vibration control of a multi-link flexible robot arm with fiber-bragg-grating sensors”. In *2009 IEEE International Conference on Robotics and Automation*, (pp. 3365-3370). IEEE.
- Kingma, D. P., & Ba, J. (2014). “Adam: A method for stochastic optimization”. *3rd International Conference for Learning Representations*, (arXiv:1412.6980).
- Kohavi, R. (1995, August). “A study of cross-validation and bootstrap for accuracy estimation and model selection”. *Proceedings of the 14th international joint conference on Artificial intelligence* (Vol. 2, pp. 1137-1143).
- Mawatari, T. and Nelson, D. (2008). A multiparameter Bragg grating fiber optic sensor and triaxial strain measurement, *Smart Materials and Structures* 17(3): 035033.
- Murtagh, F. (1991). Multilayer perceptrons for classification and regression, *Neurocomputing* 2(5-6): 183-197.
- Park, Y. L., Chau, K., Black, R. J., & Cutkosky, M. R. (2007, April). “Force sensing robot fingers using embedded fiber Bragg grating sensors and shape deposition manufacturing”. *Proceedings 2007 IEEE International Conference on Robotics and Automation* (pp. 1510-1516). IEEE.
- Santos, J. L. and Farahi, F. (2014). “*Handbook of optical sensors*”, 1 edn, CRC Press.
- Sévigny, B., Leduc, M., Faucher, M., Godbout, N., & Lacroix, S. (2009, May). “Characterization of the large index modification caused by electrical discharge in optical fibers”. *Conference on Lasers and Electro-Optics* (p. JTuD72). Optical Society of America.
- Shu, X., Zhang, L. and Bennion, I. (2002). Sensitivity characteristics of long-period fiber gratings, *Journal of Lightwave Technology* 20(2): 255-266.
- Wang, Y., Wang, D. N., Jin, W. and Rao, Y. (2007). Asymmetric transverse-load characteristics and polarization dependence of long-period fiber gratings written by a focused CO₂ laser, *Applied optics* 46(16): 3079-3086.
- Zhang, L., Liu, Y., Overall, L., Williams, J. and Bennion, I. (1999). Design and realization of long-period grating devices in conventional and high birefringence fibers and their novel applications as fiber-optic load sensors, *IEEE Journal of Selected Topics in Quantum Electronics* 5(5): 1373-1378.
- Zhou, Z., Liu, W., Huang, Y., Wang, H., Jianping, H., Huang, M. and Jinping, O. (2012). Optical fiber Bragg grating sensor assembly for 3d strain monitoring and its case study in highway pavement, *Mechanical Systems and Signal Processing* 28: 36-49.

OPTICAL TOUCH SENSOR APPLIED TO ROBOTIC EFFECTOR USING LPGS AND ARTIFICIAL NEURAL NETWORKS

Abstract. *This work presents the utilization of Long Period Fiber Gratings in bidirectional forces, as touch sensor in a robotic effector. Improvements to previous propose are presented within the neural network training to describe forces involoved in touch.*

Keywords: *optical sensor, long period grating, touch sensor, force sensor, neural network*